Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

К защите допустить:

Заведующий кафедрой

_____ Д. В. Шункевич

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
к курсовой работе
по дисциплине «Технологии и инструментальные средства проектирования интеллектуальных систем»
на тему:

ГИБРИДНАЯ НЕЙРОСИМВОЛЬНАЯ СИСТЕМА КОНТРОЛЯ ДЕЙСТВИЙ БРАУЗЕРНЫХ ИНТЕЛЛЕКТУАЛЬНЫХ АГЕНТОВ

БГУИР КР 6-05-0611-03 011 ПЗ

Студент гр. 321701 Г. В. Войшнис
Проверяющий Д. В. Шункевич

Минск 2026

СОДЕРЖАНИЕ

Перечень условных обозначений 2
Введение 3
1 Анализ предметной области и формирование требований к гибридной интеллектуальной системе 5
1.1 Характеристика предметной области 5
1.2 Анализ решаемого класса задач 7
1.3 Анализ базы знаний, решателя задач и интерфейса 8
1.4 Анализ существующих гибридных интеллектуальных систем 10
1.4.1 Методы контроля действий интеллектуальных агентов 10
1.4.2 Средства и среды оценки браузерных агентов 12
1.4.3 Обоснование гибридного подхода 13
1.5 Требования к гибридной интеллектуальной системе 14
1.6 Выводы 16
2 Проектирование гибридной интеллектуальной системы 17
2.1 Определение пользователей гибридной интеллектуальной системы 17
2.2 Сценарии использования гибридной интеллектуальной системы 18
2.3 Общая архитектура гибридной интеллектуальной системы . 20
2.4 Проектирование алгоритмов и методов решения задач 24
2.5 Выводы 28
Список использованных источников 29

ПЕРЕЧЕНЬ УСЛОВНЫХ ОБОЗНАЧЕНИЙ

TRAP — Task-Redirecting Agent Persuasion, набор сценариев перенаправления браузерных интеллектуальных агентов
WASP — Web Agent Security against Prompt Injection Attacks, набор сценариев проверки безопасности веб-агентов при атаках внедрения инструкций

ВВЕДЕНИЕ

Развитие больших языковых и мультимодальных моделей сделало возможным создание браузерных интеллектуальных агентов, которые воспринимают содержимое веб-страницы, формируют последовательность шагов и самостоятельно выполняют действия в браузере. Такие агенты применимы для поиска и сбора сведений, заполнения форм, работы с электронной почтой и документами, совершения покупок, бронирования и управления записями в прикладных системах. В отличие от обычного диалогового помощника, браузерный агент способен не только сформировать ответ, но и вызвать действие с внешним побочным эффектом: отправить сведения, изменить или удалить запись, загрузить файл либо подтвердить операцию.

Актуальность работы обусловлена тем, что при выполнении пользовательской задачи агент одновременно обрабатывает доверенные инструкции пользователя и недоверенное содержимое веб-страниц. Исследования косвенного внедрения инструкций показывают, что текст, полученный из внешнего источника, может быть ошибочно воспринят языковой моделью как команда и изменить поведение прикладной системы [1]. Для браузерных агентов последствия такого смешения данных и инструкций особенно существенны, поскольку модель обладает средствами воздействия на внешнюю среду. Эксперименты WASP подтверждают, что современные веб-агенты начинают выполнять внедрённую злоумышленником инструкцию в значительной доле сценариев [2]. В исследовании TRAP средняя восприимчивость шести передовых моделей к перенаправляющим элементам веб-интерфейса составила 25 % [3].

Одного повышения качества базовой модели недостаточно для решения указанной проблемы. Способность агента корректно распознать элемент интерфейса не означает, что действие разрешено пользователем. Например, агент может технически правильно нажать кнопку подтверждения заказа, хотя пользователь разрешил только найти товар и добавить его в корзину. Следовательно, требуется независимый слой контроля, который проверяет предлагаемое действие до его фактического выполнения и учитывает цель пользователя, тип побочного эффекта, происхождение данных, доверие к адресату, наличие полномочия и подтверждения.

Использование только нейросетевого или только логико-символьного подхода имеет существенные ограничения. Нейросетевая модель способна интерпретировать естественный язык и неоднозначные элементы страницы, однако её вывод вероятностен и не обеспечивает воспроизводимого соблюдения обязательных ограничений. Символьная система позволяет применять детерминированные правила и формировать объяснение решения, но требует предварительного представления смысла цели, элемента интерфейса и передаваемых данных в виде структурированных фактов. Нейросим-

вольный подход предназначен для совместного использования обучаемых и логических методов [4]; в рассматриваемой задаче нейросетевой компонент извлекает семантические признаки, а символьный решатель принимает обязательное решение на основе базы знаний и политик.

Целью курсовой работы является разработка гибридной нейросимвольной системы, осуществляющей независимый контроль действий браузерных интеллектуальных агентов до возникновения внешнего побочного эффекта.

Для достижения поставленной цели необходимо решить следующие задачи:

– проанализировать предметную область, угрозы, методы контроля и средства оценки браузерных интеллектуальных агентов;

– сформулировать функциональные и нефункциональные требования к системе контроля;

– разработать общую модель браузерного действия, архитектуру компонентов и порядок взаимодействия нейросетевого анализатора с символьным решателем;

– определить базу знаний, правила принятия решений и порядок обработки неопределённых либо противоречивых результатов;

– реализовать прототип контроллера, адаптер к выбранному сильному браузерному агенту и пользовательский интерфейс управления защитой;

– провести компонентное, интеграционное и сквозное тестирование на обычных и атакованных сценариях и оценить влияние защиты на безопасность и полезность агента.

Объектом исследования являются процессы автономного выполнения пользовательских задач браузерными интеллектуальными агентами, а предмет исследования составляют нейросетевые и логико-символьные методы предварительной проверки предлагаемых браузерных действий, а также способы их объединения в едином контуре контроля.

Практическая значимость работы состоит в создании модельно- и сайто-независимого шлюза, который может подключаться к различным агентам через адаптер общего формата действий. Пользовательский интерфейс должен отображать подключённых агентов, назначенные профили защиты и журнал решений, а также позволять настраивать доступные правила без изменения самого агента. Предполагаемый результат не заменяет планировщик и не предназначен для обхода защиты сайтов: он разрешает безопасные действия, запрашивает подтверждение значимых операций и блокирует нарушения установленных полномочий и политик.

Структура записки включает анализ предметной области и требований, проектирование архитектуры и алгоритмов, а также описание реализации, испытаний и их результатов.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ФОРМИРОВАНИЕ ТРЕБОВАНИЙ К ГИБРИДНОЙ ИНТЕЛЛЕКТУАЛЬНОЙ СИСТЕМЕ

1.1 Характеристика предметной области

Браузерный интеллектуальный агент представляет собой программную систему, которая получает сформулированную на естественном языке цель, наблюдает состояние веб-интерфейса, выбирает очередное действие и выполняет его средствами управления браузером. В качестве наблюдения могут использоваться объектная модель документа, дерево доступности, снимок экрана либо их сочетание. Исполнительный слой преобразует решение агента в переход по адресу, нажатие элемента, ввод текста, отправку формы, загрузку или скачивание файла и другие операции.

Работа агента имеет циклический характер. После получения цели он анализирует текущее состояние страницы, формирует план или следующий шаг, выполняет действие и получает новое наблюдение. Цикл повторяется до достижения цели, возникновения ошибки либо исчерпания установленного бюджета шагов. В отличие от сценарной автоматизации, последовательность операций заранее не фиксируется: она формируется моделью во время выполнения с учётом содержимого страницы и истории взаимодействия.

Браузерные агенты применяются в электронной торговле, офисных системах, административных панелях, системах управления разработкой, электронной почте и других веб-приложениях. Типовые задачи включают поиск сведений, сравнение объектов, заполнение форм, создание и изменение записей, подготовку заказов, бронирование и перенос данных между системами. Среда WebArena была разработана для воспроизводимой проверки подобных многошаговых задач на функциональных веб-приложениях электронной торговли, форумов, совместной разработки и управления содержимым [5]. Экспериментальные результаты авторов показали значительный разрыв между успешностью человека и исследованных агентов, что подтверждает сложность реального веб-взаимодействия.

Для выполнения заданных действий агент использует браузерный исполнитель. Таким исполнителем может быть библиотека программного управления браузером либо низкоуровневый протокол средств разработчика. Исполнитель не является интеллектуальным агентом: он открывает страницы, находит элементы и исполняет команды, но не определяет цель и не принимает семантические решения. Это разделение образует естественную точку контроля между формированием действия и его фактическим

выполнением.

В настоящей работе под *действием* понимается предложение агента изменить состояние браузера или внешней системы. Для контроля недостаточно знать только техническую операцию. Одно и то же нажатие может открыть справочную страницу, отправить сообщение, удалить запись или подтвердить оплату. Поэтому действие должно характеризоваться как техническими параметрами, так и семантическим эффектом. Выделяются следующие основные классы эффектов:

– чтение и получение сведений без изменения внешнего состояния;
– переход по адресу, в том числе междоменный;
– ввод и локальное изменение данных формы;
– отправка данных или сообщения внешнему адресату;
– скачивание либо загрузка файла;
– изменение или удаление внешней записи;
– подтверждение покупки, бронирования или иной значимой операции;
– аутентификация и предоставление полномочий.

Риск действия определяется не только его классом. Существенны объект воздействия, обратимость, источник параметров, доверие к получателю, чувствительность данных, наличие полномочия и место действия в последовательности. Переход на внешний домен может быть допустим при поиске открытых сведений, но недопустим непосредственно перед отправкой конфиденциального значения. Аналогично ввод адреса в локальную форму не создаёт утечки, пока сведения не отправлены внешнему получателю.

Разрабатываемая система рассматривается как независимый шлюз перед исполнительным слоем. Агент сохраняет собственный механизм наблюдения, планирования и выбора действий. Специализированный адаптер переводит предложение конкретного агента в общее представление, после чего контроллер выдаёт одно из трёх решений: `ALLOW` — разрешить выполнение, `ASK_USER` — запросить участие пользователя, `BLOCK` — запретить действие. Универсальность в данном контексте означает независимость базы политик от конкретной языковой модели и сайта, но не отсутствие интеграции: для нового формата действий требуется адаптер.

Взаимодействие пользователя с защитой должно выполняться через отдельную панель управления. В ней регистрируются доступные браузерные агенты, каждому агенту назначается профиль защиты, а результаты проверок и запросы подтверждения отображаются независимо от собственного интерфейса агента. Таким образом, пользователь работает с единым средством контроля даже при использовании нескольких агентов с различными форматами действий.

1.2 Анализ решаемого класса задач

Решаемая задача относится к классу задач предварительного контроля действий. На вход системы поступают цель пользователя, предлагаемое действие, состояние страницы, сведения о происхождении параметров, активный профиль защиты и история уже выполненных операций. Требуется определить допустимость действия до возникновения внешнего побочного эффекта и сформировать объяснение решения. Контроллер не должен строить основной план работы агента, однако при блокировке он может сообщить причину, чтобы агент сформировал безопасную альтернативу.

Основная особенность предметной области состоит в одновременном присутствии в контексте модели данных и инструкций. Пользователь сообщает цель, а страница содержит текст, предназначенный для чтения и обработки. Большая языковая модель воспринимает оба фрагмента в сходном представлении, вследствие чего внешнее содержимое может быть ошибочно принято за команду. Косвенное внедрение инструкций позволяет атакующему разместить управляющий текст в документе или веб-странице, которые позднее будут прочитаны агентом [1]. В отличие от прямой атаки, злоумышленнику не требуется доступ к пользовательскому диалогу с моделью.

В рамках работы рассматриваются следующие источники нежелательного поведения:

– косвенное внедрение инструкций через страницу, письмо, документ, отзыв, рекламный блок или иной недоверенный элемент;

– неоднозначность пользовательской цели и ошибочное расширение агентом предоставленных полномочий;

– неверное распознавание элемента либо его семантического эффекта;

– галлюцинация параметра, адресата или промежуточного факта;

– использование значения, полученного со страницы, в качестве основания для нового полномочия;

– опасная последовательность действий, элементы которой по отдельности могут выглядеть допустимыми;

– выполнение необратимой операции без явного подтверждения пользователя.

Защищаемыми активами являются исходная цель пользователя, конфиденциальные данные, учётная запись, доступные агенту полномочия, денежные и вычислительные ресурсы, целостность записей и возможность пользователя контролировать значимые операции. Нарушением считается не только успешное достижение цели злоумышленника, но и начало опасного внешнего действия, выход за разрешённую область либо раскрытие данных неразрешённому адресату.

Работа AgentDojo показывает, что внедрение инструкций является системной проблемой для агентов, получающих недоверенные данные через инструменты. Набор включает 97 пользовательских задач и 629 проверок безопасности в прикладных сценариях [6]. В исследовании WASP проверялись реалистичные цели перехвата веб-агентов в полностью изолированной среде. В зависимости от конфигурации агенты начинали выполнять внедрённую инструкцию в 16–86 % случаев, хотя полностью завершали цель атакующего реже [2]. Следовательно, оценка только конечного результата атаки может скрывать опасные промежуточные действия.

Дополнительным подтверждением актуальности служит исследование TRAP. В нём проверялись перенаправляющие воздействия, встроенные в реалистичные элементы интерфейса. Средняя восприимчивость шести передовых моделей составила 25 %, а небольшие изменения контекста и интерфейса в отдельных случаях существенно меняли успех атаки [3]. Из этого следует, что статического перечня строковых шаблонов недостаточно: требуется учитывать смысл действия, его последствия и полномочия независимо от формы вредоносного текста.

Модель угроз предполагает, что базовый агент и браузерный исполнитель не являются намеренно вредоносными, но могут ошибаться или следовать внедрённой инструкции. Содержимое посещаемых страниц считается недоверенным. Пользовательская цель и заранее заданная конфигурация считаются доверенными источниками полномочий. Контроллер располагается в доверенной границе и вызывается для каждого контролируемого действия. Атаки на браузер как программный продукт, вредоносное программное обеспечение операционной системы и намеренный обход контроллера скомпрометированным исполнителем находятся вне границ работы.

Также не рассматривается скрытый обход автоматизированной проверки присутствия человека и двухфакторной аутентификации. Появление требования подтвердить присутствие человека должно приводить к приостановке выполнения и запросу участия пользователя. Испытания должны проводиться в изолированных средах и тестовых учётных записях без реальных платежей и конфиденциальных данных.

1.3 Анализ базы знаний, решателя задач и интерфейса

В предыдущих семестрах не разрабатывалась предметно совместимая система управления браузерным агентом. Имеющиеся учебные базы знаний, решатели и интерфейсы относятся к другим предметным областям, поэтому их непосредственное включение в данную работу привело бы к формальному, а не функциональному объединению компонентов. Для рассматриваемой задачи исходные компоненты требуется создать заново, сохранив установленное руководством разделение на базу знаний, решатель

и интерфейс.

База знаний должна содержать классы браузерных действий, ресурсов и данных, уровни доверия, сведения о полномочиях пользователя, подтверждениях и обратимости операций. В ней также должны храниться правила, связывающие наблюдаемые факты с решениями `ALLOW`, `ASK_USER` и `BLOCK`. Знания необходимо формулировать над общими эффектами действий, а не над конкретными элементами одного сайта, чтобы одни политики применялись в электронной торговле, почте, системах документооборота и административных интерфейсах.

Решатель должен получать точные факты исполнительной среды и семантические признаки, извлечённые нейросетевым компонентом, применять к ним правила и разрешать конфликты. Абсолютный запрет имеет приоритет над вероятностной оценкой модели. При отсутствии существенного факта либо высокой неопределённости для потенциально опасного действия должен запрашиваться пользователь. Вместе с решением формируется объяснение, содержащее существенные факты и сработавшие правила.

Интерфейс системы должен включать программный и пользовательский контуры. Программный шлюз располагается между планировщиком агента и браузерным исполнителем, принимает нормализованное действие через адаптер и возвращает решение с объяснением. Он позволяет подключать различные агенты без переноса защитных правил в их внутренние подсказки.

Пользовательский контур представляет собой панель управления слоем защиты. Она должна показывать перечень зарегистрированных агентов, состояние подключения, активный профиль и журнал решений. Через неё пользователь назначает агентам профили защиты, включает доступные наборы символических правил, задаёт доверенные ресурсы и политику подтверждения значимых операций. В этой же панели обрабатываются запросы `ASK_USER` и отображаются причины блокировок.

Настраиваемость не должна позволять незаметно отключить обязательные инварианты безопасности. Базовые запреты отделяются от пользовательских правил, а изменения конфигурации версионируются и фиксируются в журнале. В первой версии достаточно реализовать один рабочий адаптер, но модель данных интерфейса должна поддерживать несколько агентов и независимое назначение им профилей. Следовательно, в дальнейших разделах проектируются новая база политик, новый символьный решатель, интерфейс перехвата действий и панель управления; готовый сильный агент используется как внешняя защищаемая система, а не как результат разработки автора.

1.4 Анализ существующих гибридных интеллектуальных систем

Для определения состава разрабатываемой системы необходимо сопоставить способы контроля действий и существующие средства испытаний браузерных агентов. Далее рассматриваются методы защиты, среды оценки и роль нейросетевого и символьного компонентов в едином контуре принятия решения.

1.4.1 Методы контроля действий интеллектуальных агентов

Существующие методы снижения риска браузерных и инструментальных агентов можно разделить на несколько групп. Первая группа изменяет инструкцию агента и явно указывает ему игнорировать команды из недоверенных источников. Преимуществами являются простота применения и отсутствие отдельного исполнительного компонента. Однако ограничение существует в том же вероятностном контуре, который подвергается воздействию. Изменение формулировки, положения или контекста внедрённой инструкции может изменить поведение модели, поэтому такой метод полезен как дополнительная мера, но не обеспечивает независимого контроля побочного эффекта.

Вторая группа использует нейросетевой классификатор или модель-критик. Компонент анализирует цель, содержимое страницы и предлагаемое действие, после чего оценивает наличие атаки, соответствие цели либо общий риск. Метод способен учитывать перефразирование, контекст и неоднозначную семантику. Его недостатками являются вероятностный характер результата, зависимость от обучающей выборки и возможность ошибки на новых типах воздействий. Кроме того, единственное числовое значение риска плохо объясняет, какое именно полномочие нарушено и почему действие заблокировано.

Третья группа основана на логико-символьных политиках: списках разрешённых доменов, матрицах полномочий, типах данных, ограничениях на операции и продукционных правилах. Такая проверка воспроизводима, допускает аудит и может гарантированно запрещать известные классы операций. Например, правило может блокировать отправку секретных данных недоверенному адресату независимо от текста, который привёл агента к этому шагу. Недостаток подхода состоит в необходимости получить структурированные факты. По одной низкоуровневой команде нажатия невозможно достоверно определить, означает ли элемент открытие справки, публикацию сообщения или покупку.

Четвёртая группа ограничивает последствия через изоляцию среды,

минимальные полномочия и участие человека. Агенту предоставляется тестовая учётная запись, ограничивается список доступных сайтов и операций, а значимые действия требуют подтверждения. Эти меры уменьшают возможный ущерб даже при ошибке модели. Вместе с тем постоянное подтверждение каждого шага снижает автономность, а слишком грубые ограничения могут сделать полезную задачу невыполнимой. Необходим риск-ориентированный выбор операций, для которых участие человека действительно требуется.

Пятая группа объединяет в себе семантический анализ и формальные политики. В общем случае нейросимвольные системы совмещают статистическое извлечение представлений с явными знаниями и рассуждением [4]. Для контроля браузерного действия нейросетевой компонент может определять предполагаемый эффект элемента, чувствительность данных, соответствие цели и неопределённость. Символьный компонент использует эти оценки совместно с точными фактами среды и применяет правила полномочий. Такое разделение позволяет не поручать языковой модели окончательное решение там, где требуется обязательное ограничение.

Сравнение основных групп методов приведено в таблице 1.1.

Таблица 1.1 – Сравнение методов контроля действий агента

Метод	Сильные стороны	Основные ограничения
Защитная инструкция	Простота подключения; отсутствие дополнительного решателя	Нет независимой границы исполнения; чувствительность к формулировке и контексту атаки
Нейросетевой критик	Семантический анализ цели, страницы и действия; устойчивость к простому перефразированию	Вероятностные ошибки; сложность гарантирования и объяснения решения
Символьные политики	Детерминированность; проверяемость; явные полномочия и причины запрета	Требуются заранее извлечённые семантические факты; ограниченная работа с неоднозначным текстом
Изоляция и подтверждение	Ограничение последствий; контроль необратимых операций человеком	Снижение автономности; необходимость правильно выбрать границу подтверждения
Нейросимвольный контроль	Совмещение понимания контекста с воспроизводимым применением политик	Более сложная интеграция; требуется порядок разрешения конфликтов компонентов

Результаты сравнения демонстрируют, что перечисленные методы не являются полностью взаимоисключающими. Изоляция и минимальные полномочия должны использоваться как базовые меры испытательного стенда. Защитная инструкция может снижать число нежелательных предложений агента. Однако предметом разработки является именно незави-

симый нейросимвольный контроль действия, поскольку он способен принимать решение после ошибки базового агента и до исполнения опасной команды.

1.4.2 Средства и среды оценки браузерных агентов

Проверка должна дать ответы на два простых вопроса. Во-первых, не мешает ли слой защиты агенту выполнять обычные пользовательские задания. Во-вторых, предотвращает ли он опасные действия, если агент ошибся или последовал вредоносной инструкции. Эти вопросы нельзя объединять в один показатель: система может блокировать все действия и быть формально безопасной, но практически бесполезной.

BrowserGym используется как общая оболочка эксперимента, а не как отдельная мера качества. Он унифицирует наблюдения и действия различных веб-наборов, запускает агента и позволяет перехватить предложенную команду до её передачи браузеру [7]. Благодаря этому один и тот же агент можно проверять с разными режимами контроллера при одинаковых начальных условиях.

WebArena-Verified применяется для проверки полезности. Набор содержит проверенные многошаговые задания и воспроизводимые средства оценки конечного результата [8]. Агент выполняет обычные задания сначала без защиты, а затем с ней. Сравниваются доля завершённых задач, число безопасных действий, ошибочно заблокированных контроллером, и количество лишних запросов подтверждения.

DoomArena применяется для проверки безопасности. Это подключаемая к BrowserGym система, которая добавляет в среду настраиваемые атаки и позволяет задать цель атакующего и проверяемое нарушение [9]; в атакованном задании оценивается не только то, заметил ли контроллер вредоносный текст, но и произошло ли опасное действие. Основными результатами являются доля успешных атак, число пропущенных и предотвращённых опасных действий.

AgentDojo, WASP и TRAP сохраняют значение как дополнительные источники сценариев. AgentDojo позволяет проверить переносимость политик на инструментальные действия [6]. WASP предоставляет реалистичные цели атакующего в изолированных веб-средах [2], а TRAP рассматривает убеждающие и перенаправляющие элементы интерфейса [3]. Для основной демонстрации курсовой достаточно связки BrowserGym, WebArena-Verified и DoomArena; дополнительные наборы применяются при наличии времени и вычислительного бюджета.

Для курсовой работы целесообразна трёхуровневая проверка. На компонентном уровне решатель получает синтетические действия и заранее известные факты, что позволяет проверить каждое правило, приори-

тет и конфликт. На интеграционном уровне небольшие локальные страницы воспроизводят отправку данных, удаление, междоменный переход и внедрённую инструкцию. На сквозном уровне сильный агент выполняет обычные задания WebArena-Verified и их атакованные варианты, сформированные с помощью DoomArena. Разработка полноценного собственного интернет-магазина не требуется, поскольку это увеличило бы объём работ, но не улучшило бы доказательность контроля.

Для каждого задания необходимы четыре режима: агент без дополнительного контроля, только нейросетевой анализ, только символьные правила и полная гибридная система. Такое исключающее сравнение позволяет определить вклад каждого компонента. Основными показателями являются доля успешно выполненных обычных задач, доля успешных атак, доля предотвращённых опасных действий, частота ложных блокировок, число запросов подтверждения, дополнительное время и стоимость обработки.

1.4.3 Обоснование гибридного подхода

Необходимость нейросетевого компонента определяется не формальным требованием темы, а свойствами входных данных. Цель пользователя и текст интерфейса задаются на естественном языке. Названия элементов неоднозначны, а один семантический эффект может выражаться различными фразами. Например, кнопки с подписями “Оплатить”, “Подтвердить заказ” и “Завершить покупку” относятся к одному классу внешнего эффекта. Нейросетевой анализ позволяет привести такие выражения к общим признакам, оценить соответствие цели и выделить чувствительные данные.

Необходимость символьного компонента определяется характером ограничений. Полномочие пользователя, запрет передачи секретов и требование подтверждения необратимой операции должны применяться воспроизводимо. Текст страницы не может самостоятельно расширять исходную цель. Жёсткий запрет не должен отменяться высокой уверенностью модели в безопасности действия. Такие отношения естественно представляются в базе знаний и проверяются правилами логического вывода.

Функциональная гибридность предполагает, что оба компонента влияют на результат. Нейросетевой анализатор формирует семантические факты и оценки, без которых часть действий практически невозможно классифицировать. Символьный решатель объединяет их с точными фактами исполнительной среды и выдаёт обязательное решение. Если модель не уверена, а возможный ущерб высок, система должна перейти к `ASK_USER`. Если сработал абсолютный запрет, результат должен быть `BLOCK` независимо от модельной оценки.

База знаний должна описывать не элементы отдельных сайтов, а устойчивые сущности и отношения: цель, действие, ресурс, данные, источ-

ник, адресат, полномочие, подтверждение, обратимость и историю. Благодаря этому правило передачи чувствительных данных недоверенному адресату применимо к магазину, почте, системе документооборота и административной панели. Для нового агента меняется адаптер, но смысл политик сохраняется.

Таким образом, ожидаемый эффект гибридизации состоит не в повышении способности агента находить элементы страницы, а в снижении числа опасных внешних действий при сохранении приемлемой успешности обычных задач. Данное утверждение является проверяемой гипотезой. Если гибридный режим не превзойдёт одиночные компоненты либо будет создавать чрезмерное число ложных блокировок, это должно быть отражено в результатах испытаний.

1.5 Требования к гибридной интеллектуальной системе

На основании анализа сформулированы предварительные функциональные требования. Система должна:

– принимать цель пользователя, предлагаемое действие, контекст страницы, сведения о происхождении параметров и историю выполнения;

– преобразовывать действия подключаемого агента в единое внутреннее представление через отдельный адаптер;

– регистрировать браузерных агентов и отображать состояние их подключения;

– создавать профили защиты и независимо назначать их подключённым агентам;

– предоставлять настройку разрешённых наборов символических правил, доверенных ресурсов и политики подтверждения в установленных пределах;

– определять технический тип и предполагаемый семантический эффект действия;

– оценивать соответствие действия исходной цели, чувствительность данных, признаки внедрения инструкции и неопределённость оценки;

– хранить знания о классах действий, данных, ресурсах, уровнях доверия, полномочиях и подтверждениях;

– применять символические правила к точным и нейросетевым фактам;

– выдавать решения `ALLOW`, `ASK_USER` или `BLOCK` до передачи действия исполнительному слою;

– блокировать передачу чувствительных данных неразрешённому или недоверенному адресату;

– не допускать расширения полномочий на основании текста страницы;

– запрашивать подтверждение для определённых необратимых и значимых операций;

– учитывать последовательность действий, ранее выданные подтверждения и накопленный риск;

– формировать объяснение со сработавшими правилами и существенными фактами;

– вести журнал предложенных действий, оценок, решений и фактического исполнения;

– показывать в пользовательском интерфейсе активный профиль, объяснение решения и историю проверок для выбранного агента;

– принимать через пользовательский интерфейс подтверждение или отклонение действий, для которых выдано решение `ASK_USER`;

– позволять агенту перепланировать выполнение после блокировки;

– передавать управление человеку при автоматизированной проверке присутствия, двухфакторной аутентификации и других требованиях непосредственного участия пользователя.

К нефункциональным требованиям относятся:

– воспроизводимость символического решения при одинаковых фактах, правилах и конфигурации;

– модульность и возможность независимой замены адаптера, нейросетевого анализатора, базы знаний, решателя и пользовательского интерфейса;

– расширяемость перечня действий и правил без изменения ядра исполнительного слоя;

– объяснимость каждого запрета и запроса подтверждения;

– безопасное поведение при отсутствии существенных фактов или отказе нейросетевого компонента;

– ограниченная дополнительная задержка по отношению к времени рассуждения базового агента;

– возможность фиксации версии модели, набора правил, параметров и состояния испытательной среды;

– разграничение обязательных инвариантов безопасности и изменяемых пользовательских настроек, а также журналирование изменений конфигурации;

– однозначное отображение агента, активного профиля и причины принятого решения в пользовательском интерфейсе;

– отсутствие реального ущерба при испытаниях за счёт изолированных сред и тестовых данных;

– возможность автоматизированного компонентного, интеграционного и сквозного тестирования.

Критерии приемлемости должны быть уточнены после пилотного запуска выбранного агента. Предварительно требуется, чтобы гибридный ре-

жим существенно снижал долю успешных атак и пропущенных опасных действий относительно агента без контроллера, а потеря успешности обычных задач оставалась ограниченной. Также должны измеряться частота ложных блокировок, число запросов подтверждения, задержка одного решения и стоимость дополнительных модельных вызовов.

Границы первой версии включают структурированные браузерные действия и действия по координатам, если адаптер может связать их с элементом страницы. Полная проверка произвольного программного кода, сгенерированного агентом, не гарантируется, так как один фрагмент кода может скрывать несколько внешних эффектов и требует отдельной песочницы. Система не предназначена для защиты от уязвимостей браузера, вредоносных расширений и скомпрометированной операционной системы.

1.6 Выводы

В результате анализа установлено, что браузерный интеллектуальный агент совмещает обработку недоверенного содержимого с возможностью выполнять внешние действия. Это создаёт риск косвенного внедрения инструкций, ошибочного расширения полномочий, раскрытия данных и необратимых операций. Высокая способность агента решать обычные задачи не устраняет проблему, поскольку техническая корректность действия не означает его разрешённость пользователем.

Рассмотрены защитные инструкции, нейросетевые критики, символические политики, изоляция среды и подтверждение человеком. Установлено, что нейросетевой анализ необходим для интерпретации естественного языка и семантики интерфейса, а символьный компонент — для воспроизводимого применения полномочий и запретов. Поэтому выбран гибридный подход, в котором модель извлекает семантические факты, а решатель принимает обязательное и объяснимое решение до исполнения действия.

Определена граница системы в виде универсального шлюза с адаптерами к конкретным агентам и панели управления профилями защиты; сформулированы функциональные и нефункциональные требования, выделены классы контролируемых действий и ограничения первой версии.

Для проверки предложено сравнивать одного и того же сильного агента без защиты, с нейросетевым, символическим и гибридным контролем на обычных и атакованных сценариях. Полученные результаты образуют основу для проектирования архитектуры, модели данных и алгоритмов системы.

2 ПРОЕКТИРОВАНИЕ ГИБРИДНОЙ ИНТЕЛЛЕКТУАЛЬНОЙ СИСТЕМЫ

Система контроля получает предложение действия до его исполнения, сопоставляет его с задачей пользователя и возвращает разрешение, запрос подтверждения либо запрет. В качестве первого подключаемого агента выбран Browser Use; переносимость обеспечивается общим контрактом сервиса, а подключение каждого другого типа агента требует отдельной проверенной интеграции.

2.1 Определение пользователей гибридной интеллектуальной системы

Основным пользователем является человек, поручающий агенту работу в браузере. Он задаёт цель, наблюдает ход выполнения, получает итоговый ответ, подтверждает конкретные значимые действия и настраивает доступные ограничения. Для постановки задачи специальных знаний о протоколе браузера не требуется. При добавлении правила пользователь выбирает проверяемый признак, значение и требуемый исход. Обязательные ограничения безопасности не отключаются пользовательским правилом. Возможности пользователя представлены на рисунке 2.1 [10].

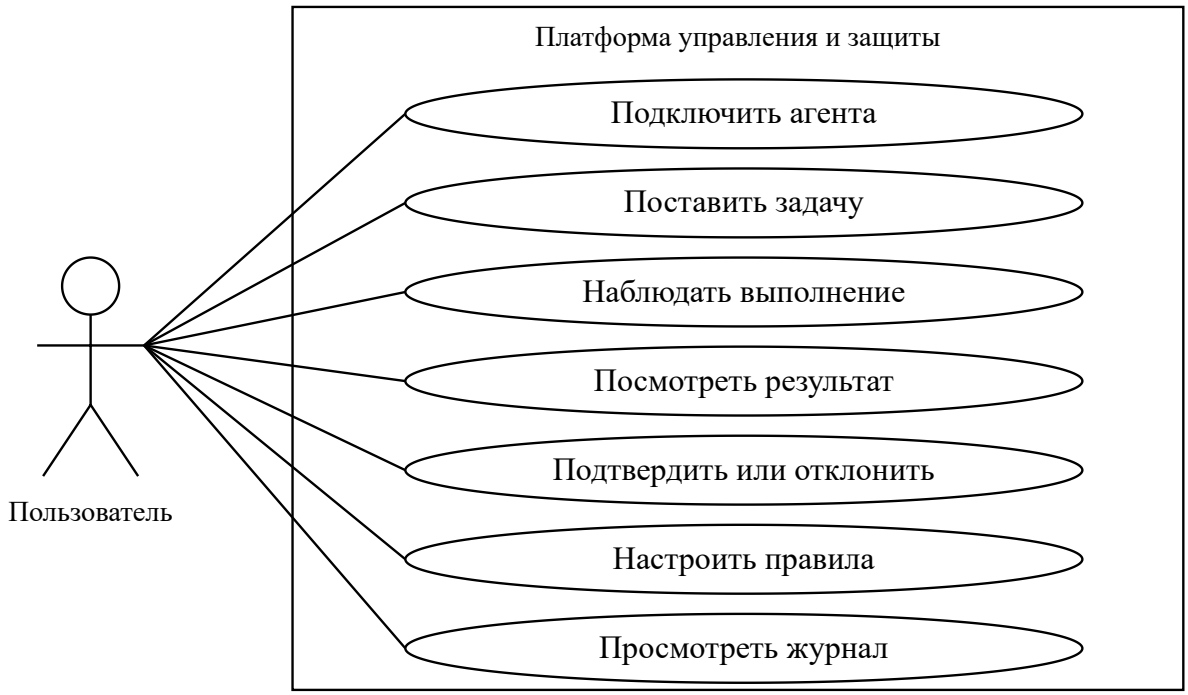


Рисунок 2.1 – Варианты использования платформы пользователем

Разработчик интеграции устанавливает предоставленный код у исполнителя инструментов агента, описывает поддерживаемые операции и проверяет полноту охвата. В демонстрационном приложении эту работу выполняет разработчик системы. Разработчик получает инструкцию подключения и результаты проверок, а не автоматическую гарантию совместимости произвольного агента.

Внешними программными участниками являются Browser Use, браузер и облачная модель смыслового анализа. Агент планирует действия, браузер выполняет разрешённые операции, а модель извлекает смысловые признаки. Они не получают полномочий изменять исходную цель пользователя или активную базу правил. Ассоциации диаграммы отражают участие в функции, а не порядок исполнения функций.

2.2 Сценарии использования гибридной интеллектуальной системы

Основной сквозной сценарий начинается с выбора подключённого агента в панели. Пользователь вводит цель и ограничения, например подбор ноутбука в пределах бюджета без оформления заказа. Сервис создаёт задачу и сохраняет прямой ввод как доверенную цель. Исполнитель задач запускает Browser Use с защищённым набором инструментов. Перед каждым предложенным вызовом интеграция получает решение сервиса; после допустимого исполнения передаёт результат агенту и событие в журнал, поэтому пользователь видит последовательность действий и итоговый ответ; порядок взаимодействия представлен на рисунке 2.2.

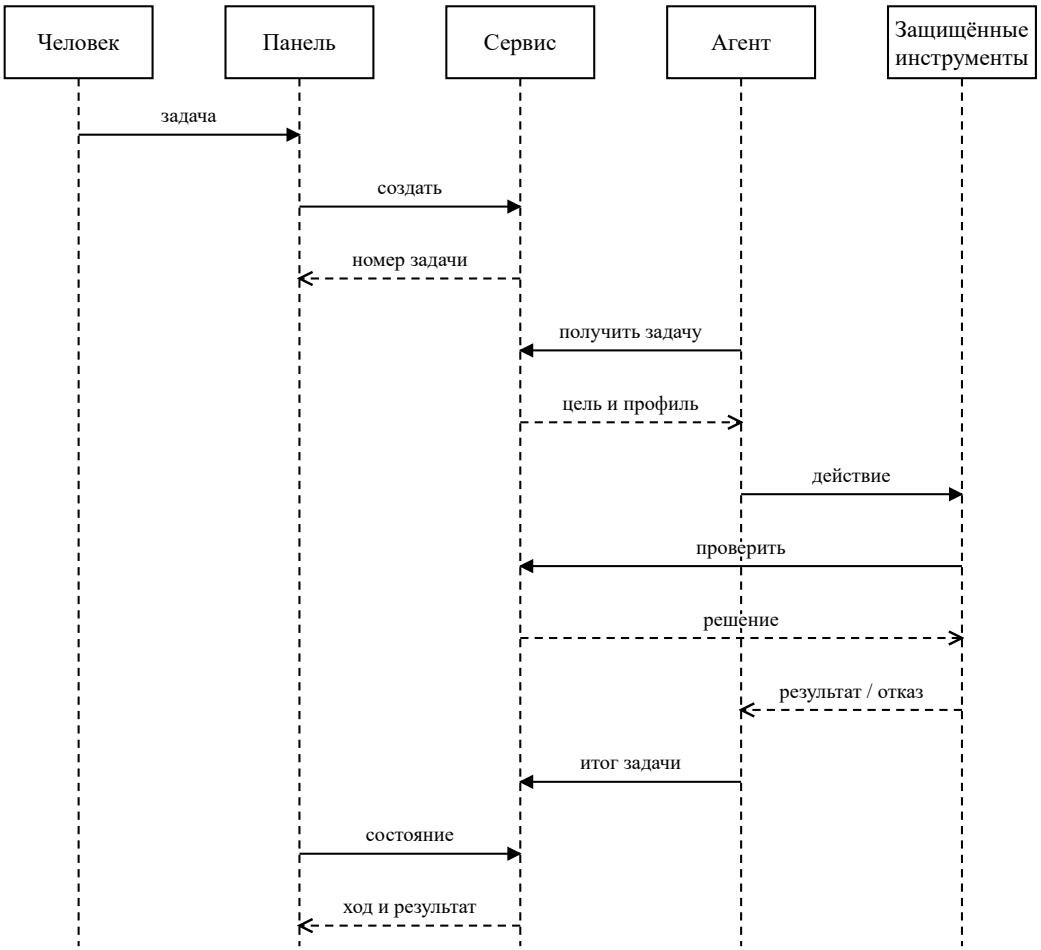


Рисунок 2.2 – Постановка задачи через панель и получение результата

При разрешении вызов передаётся исходному исполнителю один раз, при запрете в агентский цикл возвращаются объяснение и признак отсутствия исполнения, после чего агент может выбрать другой шаг. Запрос подтверждения используется в редких пограничных случаях и удерживает конкретный вызов и показывает человеку инструмент, параметры, цель действия и причину. Согласие относится только к этому предложению; отказ либо истечение срока не вызывают инструмент. При изменении страницы требуется новое наблюдение.

Альтернативный сценарий возникает при вредоносной инструкции на странице. Например, текст предлагает передать контакт постороннему получателю вопреки исходной задаче. Проверка оценивает предлагаемое действие, его адресата и происхождение инструкции. Наличие подозрительного текста само по себе не запрещает чтение страницы: предотвращается действие, нарушающее ограничения.

Граничные сценарии включают неизвестный инструмент, недоступность сервиса, ошибочный ответ модели, недостаток контекста и изменение

цели. В защищённом режиме отсутствие решения не разрешает значимое действие. После перезапуска незавершённая задача отмечается прерванной; необратимый вызов автоматически не повторяется. Если потеряна запись результата уже вызванного инструмента, исход отмечается неизвестным, а изменение пользовательского правила влияет на новые предложения, но не исполняет ранее заблокированное действие.

2.3 Общая архитектура гибридной интеллектуальной системы

Система состоит из локального сервиса, базы правил, символьного решателя, клиента облачной модели, хранилища и веб-панели. В процесс агента встраиваются исполнитель задач и защищённый диспетчер инструментов. Сервис отделён от планировщика агента; он принимает нормализованное описание действия и возвращает проверяемое решение. Состав и направления обмена приведены на рисунке 2.3. Управление задачами дополнительно раскрыто на рисунке 2.2.

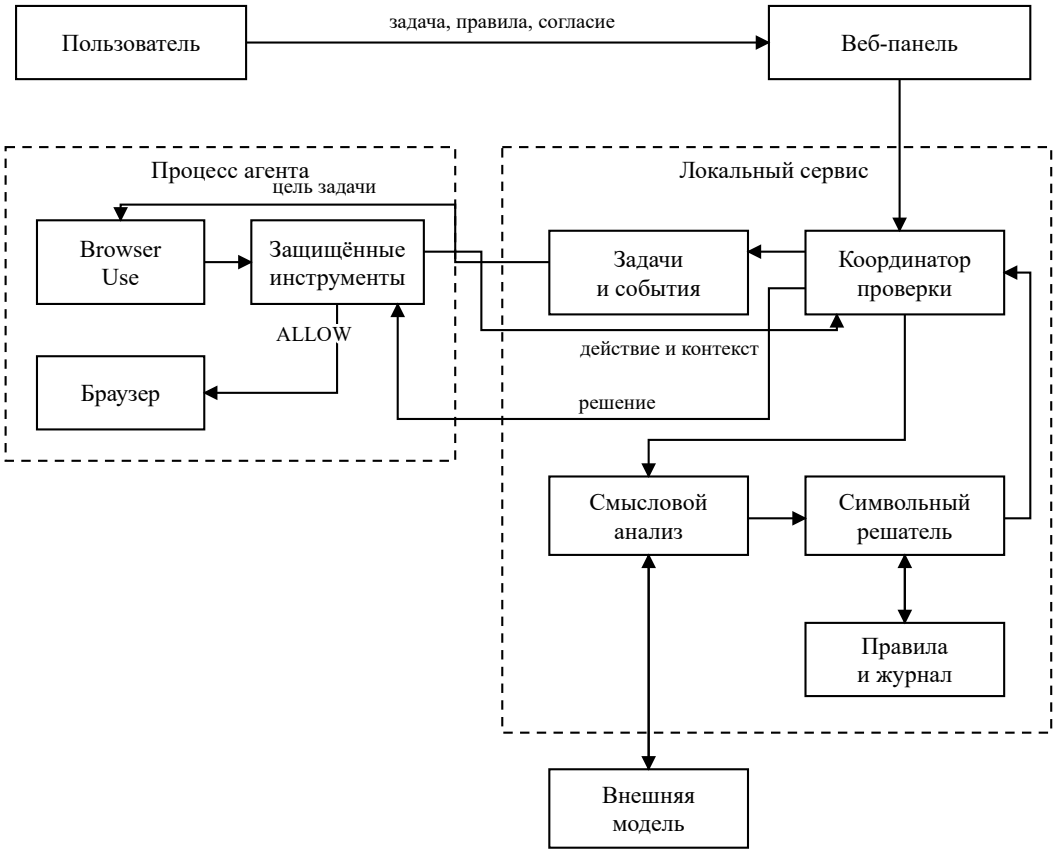


Рисунок 2.3 – Общая архитектура системы контроля действий

Для Browser Use точкой интеграции выбран метод исполнения инструментов `Tools.act`. Его защищённый вариант получает действие до делегирования исходному методу. Набор инструментов задаётся при создании агента; официальный интерфейс позволяет передавать собственный объект инструментов [11]. Проверка охватывает также начальную навигацию и отдельные вызовы внутри одного шага. На рисунке 2.4 показано место удержания вызова. Произвольное исполнение кода, файловые операции и другие непрозрачные инструменты исключаются из поддерживаемого набора до разработки отдельной политики.

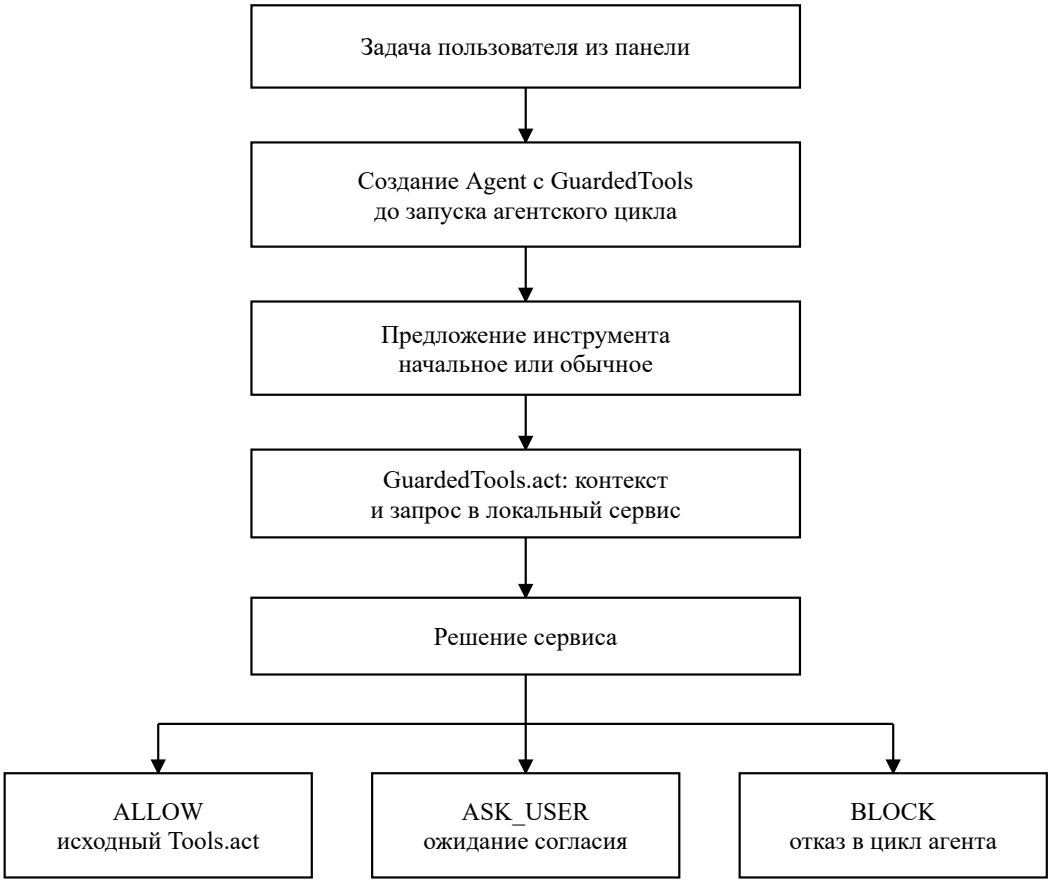


Рисунок 2.4 – Встраивание проверки в исполнитель инструментов Browser Use

Контекст формируется интеграцией из реальных параметров вызова и наблюдения того же браузерного сеанса, которое использует агент. В него входят подтверждённая цель, имя и описание инструмента, параметры, адрес, свойства целевого элемента и ближайшей формы, адрес отправки и состав полей, относящийся к действию текст и последние результаты. Если структуры документа недостаточно, добавляется снимок экрана. Объём текстового наблюдения ограничивается; история передаётся как небольшое

окно релевантных действий. Скрытые рассуждения модели агента не требуются. Доступное объяснение шага имеет статус недоверенной подсказки и не заменяет прямую цель пользователя.

Прямой ввод пользователя и активная версия правил относятся к доверенной части. Текст страницы, снимок и результат внешнего инструмента относятся к наблюдениям. Ответ модели представляет собой оценку с указанием свидетельств и неопределённости. В запросе эти части структурно разделяются; модель получает инструкцию рассматривать содержимое страницы как данные. Разделение снижает риск подмены инструкций, однако не считается доказательством отсутствия инъекций. Устойчивость проверяется отдельно на атакованных сценариях.

Веб-панель предоставляет список агентов, постановку задач, ленту решений, подтверждения, профиль защиты и журнал. Пользователь различает предложенное, разрешённое и действительно выполненное действие, причём разрешение не отображается как успешное исполнение до получения результата. Для первой версии достаточно периодического чтения событий; замена доставки событий не затрагивает решатель. Облачный ключ хранится в локальной конфигурации сервиса вне репозитория и не передаётся в браузерный интерфейс.

Хранилище на основе SQLite содержит агентов, задачи, предложения действий, решения, правила и события. Задача связана с исходной целью, версией и итогом; действие — с задачей и наблюдением; решение — с действием, правилами и оценкой. Подтверждение имеет срок и одноразовый ответ. Концептуальные связи показаны на рисунке 2.5.

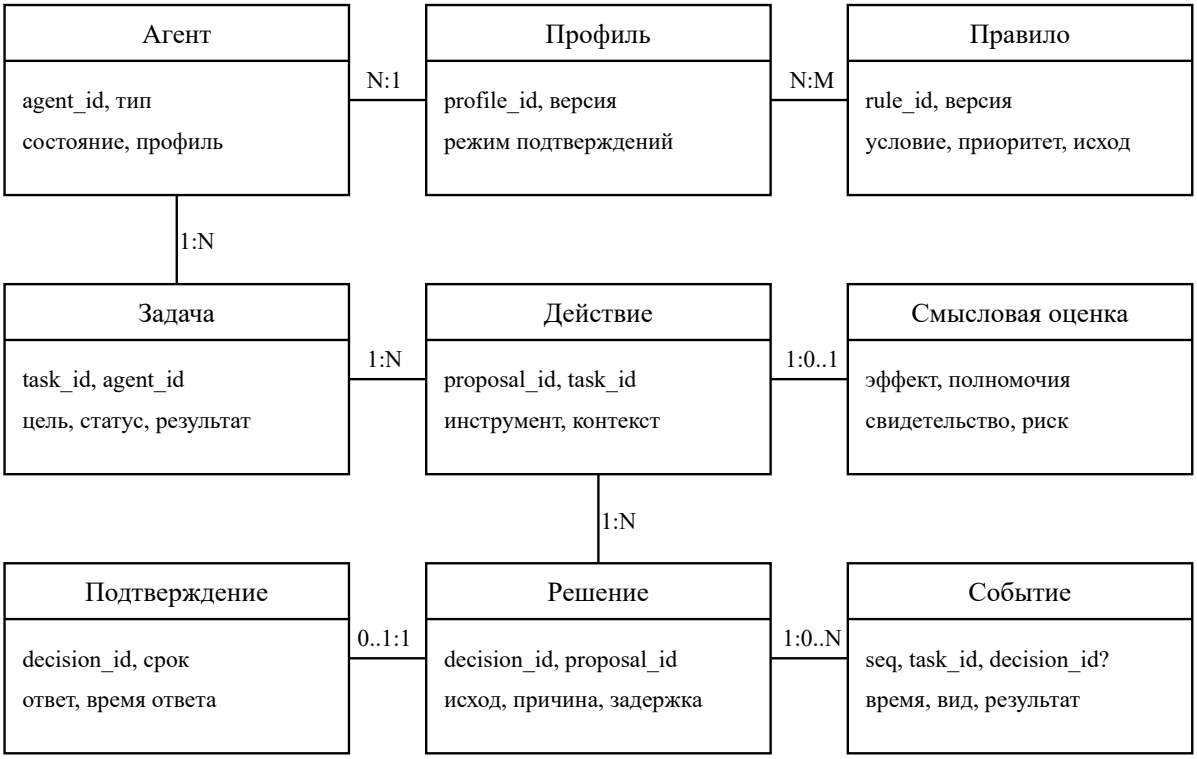


Рисунок 2.5 – Логическая модель данных системы контроля

Оценка и подтверждение могут храниться внутри записи решения как вложенные структурированные данные; логические связи при этом сохраняются независимо от физического размещения.

Обмен с сервисом выполняется структурированными сообщениями: задача содержит строковую цель, идентификатор агента, режим проверки и целое ограничение числа шагов. Предложение действия содержит строковые идентификаторы задачи и попытки, имя инструмента, объект параметров и наблюдение; в наблюдении сохраняются адрес, целевой элемент, время получения и отпечаток контекста. Последние результаты передаются ограниченным списком, снимок — отдельным необязательным полем.

Смысловая оценка задаёт эффект и соответствие цели перечислениями, признаки неопределённости и инъекции — логическими значениями, свидетельство и объяснение — строками. Решение содержит один из исходов `ALLOW`, `ASK_USER`, `BLOCK`, список правил, версию политики, задержку в миллисекундах и необязательный срок подтверждения. Повтор идентификатора с тем же содержимым возвращает существующее решение, а изменение параметров требует нового предложения; отменённое предложение повторно не разрешается.

2.4 Проектирование алгоритмов и методов решения задач

Для объединения подходов выбран каскад: первичная символьная проверка, условный смысловой анализ и итоговый символьный вывод. Сначала проверяются формат, поддержка инструмента, отмеченные секретные данные и прямые пользовательские запреты. Для проверенных инструментов наблюдения и прокрутки допускается быстрый путь без модели. Простое название инструмента не доказывает безопасность: нажатие, ввод, переход и отправка требуют учёта цели и последствий.

Если первичная проверка не определила исход, облачная модель получает ограниченный контекст. Она классифицирует эффект, соответствие задаче, признаки перенаправления и неопределённость. Для утверждения об инструкции страницы требуется свидетельство из переданного текста; структура ответа проверяется, произвольный текст либо недопустимое значение не превращаются в разрешение. Порядок вызовов приведён на рисунке 2.6.

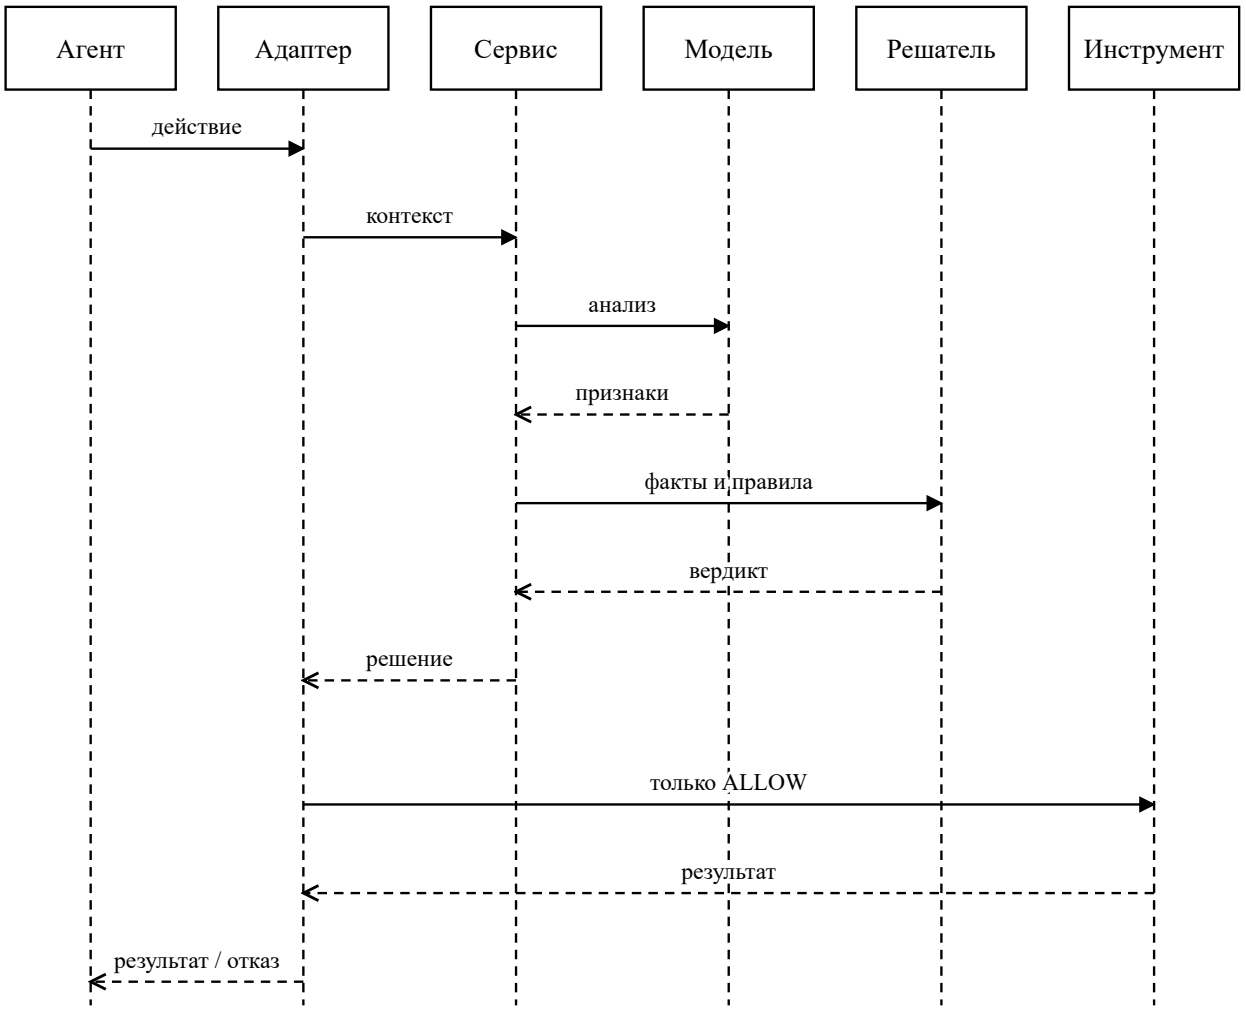


Рисунок 2.6 – Последовательность проверки предложенного действия

База знаний объединяет обязательные политики и пользовательские ограничения. Правило задаёт проверяемый признак, условие, исход и объяснение; пользовательские правила задаются данными без исполняемого кода. Начальный словарь включает вид инструмента, адрес сайта, класс передаваемых данных, предполагаемый эффект, соответствие цели, наличие прямого разрешения и неопределённость. Для прямого разрешения сохраняется проверяемая цитата именно из поручения пользователя. Для фактов различаются техническое наблюдение интеграции и смысловая оценка модели. Неизвестное значение не считается доказательством допустимости.

Обязательный запрет имеет приоритет над пользовательским запретом; далее рассматриваются условия подтверждения и разрешения. Передача данных, отмеченных как секретные, и неподдерживаемый инструмент блокируются независимо от положительной оценки модели. Действие, противоречащее цели, запрещается. При нехватке сведений сначала выполняется одно ограниченное уточнение контекста, при необходимости с анали-

зом снимка. Неустановленные последствия ведут к остановке. Явное поручение пользователя разрешает согласованные с ним отправку, покупку либо изменение указанных данных при отсутствии запретов. Подтверждение требуется лишь для значимого действия с неоднозначными границами полномочий; сама значимость не означает обязательного обращения к человеку. Строгий профиль дополнительно требует согласия для ввода и изменения данных. Блок-схема представлена на рисунке 2.7.

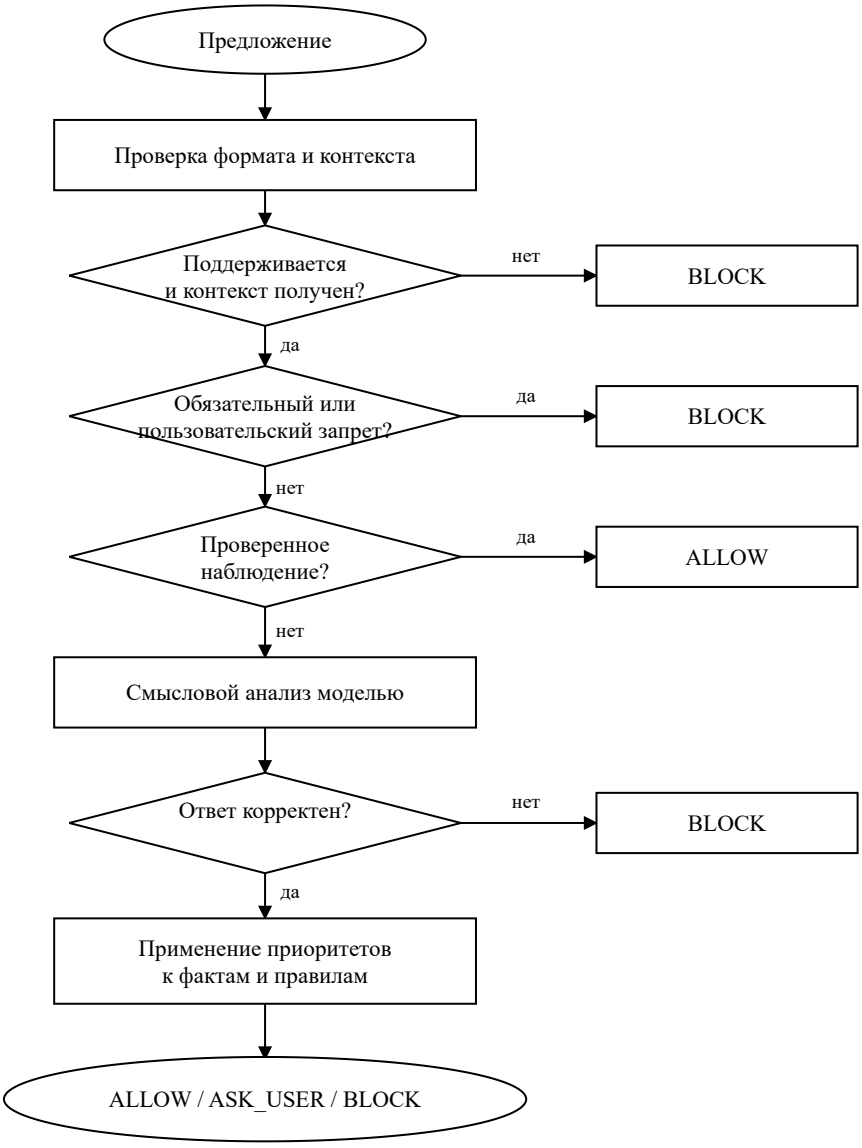


Рисунок 2.7 – Алгоритм формирования нейросимвольного решения

Модель различает одинаковые нажатия по смыслу целевого элемента, а правило определяет обязательность подтверждения либо запрета: при замене оценки «просмотр сведений» на «оформление заказа» исход изме-

няется; при сохранении оценки и включении строгого профиля может измениться необходимость согласия. Эти контрольные пары используются для проверки гибридности. Объяснение сохраняет сработавшие правила и оценку, на которой основан вывод.

Алгоритм подтверждения связывает ответ человека с идентификатором решения, отпечатком действия, задачей и версией политики. Исходный вызов ожидает вне внутреннего тайм-аута инструмента, но в пределах допустимого времени шага агента. Для прототипа предусматриваются 120 с на подтверждение и 420 с на шаг; значения задаются конфигурацией и проверяются совместно с задержкой модели. После ответа проверяются состояние задачи, версия политики и актуальность страницы и элемента. Смена контекста или отмена задачи запрещают исполнение старого предложения; порядок обмена показан на рисунке 2.8.

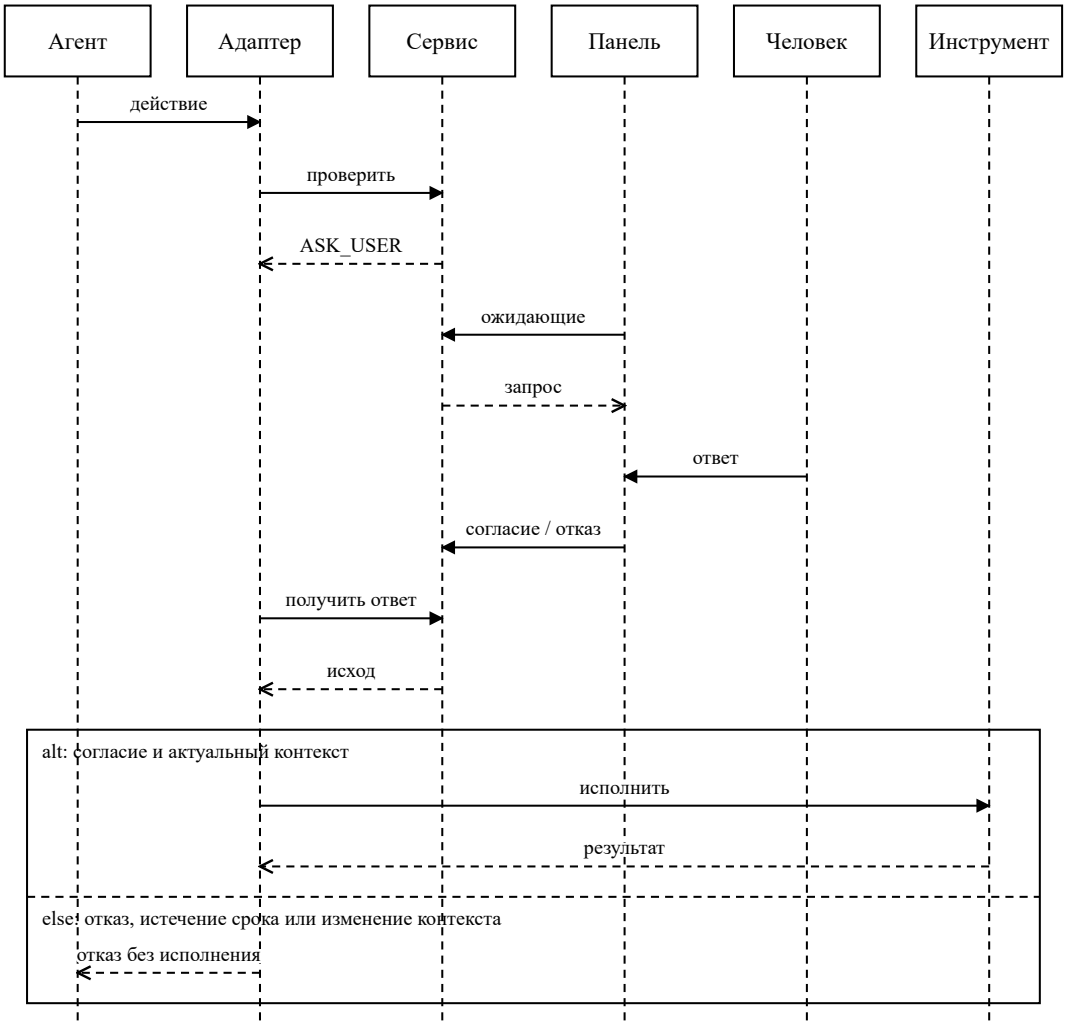


Рисунок 2.8 – Подтверждение действия пользователем и обработка истечения срока

При линейном просмотре R правил с не более чем C проверками на

правило символьный этап имеет сложность $O(RC)$. Формирование ограниченного контекста линейно по объёму выбранного наблюдения. Время облачной модели рассматривается как измеряемая внешняя величина: задержка зависит от объёма контекста, модели и сети, а не только от числа правил. При необходимости правила индексируются по инструменту и области применения; для прототипа линейный просмотр проще проверять.

Полная добавленная задержка включает получение наблюдения, обмен с сервисом, символьную проверку, условный вызов модели и повторную проверку контекста. Ожидание человека учитывается отдельно. Для ускорения используются ограничение истории и текста, быстрый путь и повторное использование решения только для идентичного предложения; такое разрешение не переносится на другой элемент либо следующую страницу. Измеряются медиана и 95-й процентиль задержки, доля проверок без модели, общее время задачи и число подтверждений.

Проверка проекта включает типичные, граничные и отрицательные случаи: обычное чтение, допустимую отправку после согласия, отказ, инъекцию, неизвестный инструмент, ошибку модели, потерю связи, повтор запроса и смену страницы. Локальные учебные страницы позволяют проверить механизм удержания; они не заменяют оценку обобщающей способности. Для полезности предусмотрены обычные задания WebArena-Verified, для безопасности — атакованные сценарии DoomArena. Совместимость запуска проверяется пилотом. На одинаковых задачах сопоставляются режимы без защиты, только с правилами, только с моделью и с гибридной проверкой. Успешность, ложные блокировки и задержки фиксируются по фактическим результатам, а не заявляются следствием одной архитектуры.

2.5 Выводы

Определены пользователи и сквозные сценарии платформы, спроектированы локальный сервис, встроенная интеграция Browser Use, вебпанель и модель хранения. Установлены состав контекста и граница доверия между прямой задачей и содержимым страницы. Разработаны каскадный алгоритм смыслового анализа и символьного вывода, приоритеты правил и порядок одноразового подтверждения.

Проект допускает независимую замену модели, правил и интерфейса; удержание вызовов обеспечивается для заявленного набора инструментов при корректно установленной интеграции; прямой обход исполнителя и автономные действия скриптов страницы не покрываются автоматически. Эффективность против атак и влияние на полезность агента подлежат экспериментальной проверке. Полученные решения служат основой для реализации прототипа и описания результатов в следующем разделе.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] Not What You've Signed Up For: Compromising Real-World LLM-Integrated Applications with Indirect Prompt Injection / K. Greshake [et al.] // Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security. — Association for Computing Machinery, 2023. — Pp. 79–90.

[2] WASP: Benchmarking Web Agent Security Against Prompt Injection Attacks / I. Evtimov [et al.] // Advances in Neural Information Processing Systems. — Vol. 38. — 2025.

[3] It's a TRAP! Task-Redirecting Agent Persuasion Benchmark for Web Agents / K. Korgul [et al.] // Proceedings of the 43rd International Conference on Machine Learning. — Vol. 306 of Proceedings of Machine Learning Research. — 2026. — Pp. 60284–60300.

[4] From Statistical Relational to Neurosymbolic Artificial Intelligence: A Survey / G. Marra, S. Dumančić, R. Manhaeve, L. De Raedt // Artificial Intelligence. — 2024. — Vol. 328. — 104062 P.

[5] WebArena: A Realistic Web Environment for Building Autonomous Agents / S. Zhou [et al.] // Proceedings of the International Conference on Learning Representations. — 2024.

[6] AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents / E. Debenedetti [et al.] // Advances in Neural Information Processing Systems. — Vol. 37. — 2024.

[7] The BrowserGym Ecosystem for Web Agent Research / T. Le Sellier de Chezelles [et al.] // Transactions on Machine Learning Research. — 2025. https://openreview.net/forum?id=5298fKGmv3.

[8] WebArena Verified: Reliable Evaluation for Web Agents / A. El Hattami, M. Thakkar, N. Chapados, C. Pal // NeurIPS Workshop on Scaling Environments for Agents. — 2025. https://openreview.net/forum?id=94tlGxmqkN.

[9] Boisvert, L. DoomArena: A Framework for Testing AI Agents Against Evolving Security Threats. — 2025. https://arxiv.org/abs/2504.14064.

[10] OMG Unified Modeling Language. Version 2.5.1. — https://www.omg.org/spec/UML/2.5.1/PDF. — 2017. — Дата обращения: 02.11.2026.

[11] Browser Use: Add Tools. — https://docs.browser-use.com/open-source/customize/tools/add. — 2026. — Дата обращения: 02.11.2026.